

**TECNOLOGIA EM BANCO DE DADOS: ÊNFASE EM DATA ANALYTICS**  
**Disciplina: Ciência de Dados e Inteligência Artificial**

**Italo Infantini Filho**

**PROCESSO DE CIÊNCIA DE DADOS NO ORANGE DATA MINING APLICADO À  
BASE TAIWANESE BANKRUPTCY PREDICTION**

**Trabalho acadêmico apresentado à disciplina de Ciência de Dados e Inteligência  
Artificial, como requisito parcial (Fase 2) para avaliação.**

**Boa Esperança, Minas Gerais**  
**2026**

## Exploração dos dados


A exploração dos dados foi realizada no Orange Data Mining com o objetivo de compreender a estrutura da base e identificar características relevantes para a modelagem. Inicialmente, o conjunto foi carregado no widget **File**, o que permitiu confirmar a presença da variável-alvo **Bankrupt?**, a quantidade de registros e a ausência de valores ausentes.

Em seguida, utilizou-se o widget **Data Table** para verificar a organização dos dados e confirmar que a variável-alvo estava corretamente representada pelas classes **0** e **1**. Depois, com o widget **Data Info**, foi possível resumir a composição da base quanto ao número de linhas, colunas e tipos de atributos.

Na etapa de análise visual, o widget **Distributions** foi empregado para examinar a distribuição da variável-alvo, evidenciando forte desbalanceamento entre as classes. Depois, o widget **Box Plot** foi utilizado para comparar a distribuição de variáveis numéricas entre empresas falidas e não falidas, permitindo observar dispersão, diferenças entre grupos e possíveis valores extremos. Por fim, o widget **Scatter Plot** foi usado para analisar a relação entre pares de variáveis numéricas, com coloração pela classe, a fim de verificar padrões de associação e possível separação entre as classes.

Esses experimentos de exploração mostraram que a base é desbalanceada, composta majoritariamente por atributos numéricos e com sobreposição entre as classes em parte do espaço de atributos. Essas observações serviram de base para a escolha dos algoritmos e para a interpretação posterior das métricas de desempenho.

Figura 1: Fluxo inicial de exploração dos dados no Orange Data Mining




## Definição dos Algoritmos de Modelagem

Foram escolhidos três algoritmos de classificação no Orange Data Mining: **Logistic Regression**, **Tree** e **Random Forest**. A seleção buscou comparar abordagens distintas de aprendizado supervisionado aplicadas ao mesmo problema de predição de falência.

A **Logistic Regression** foi escolhida como modelo de referência, por ser um classificador linear amplamente utilizado em problemas binários. A **Tree** foi incluída por representar uma abordagem baseada em regras de decisão, com maior interpretabilidade. Já o **Random Forest** foi selecionado por ser um método de ensemble baseado em múltiplas árvores, adequado para capturar relações mais complexas entre os atributos.

A comparação entre esses três algoritmos permitiu avaliar diferenças de desempenho entre um modelo linear, um modelo simples baseado em árvore e um modelo mais robusto de agregação. Essa diversidade tornou o experimento mais adequado para analisar o comportamento dos classificadores diante de uma base desbalanceada e composta por variáveis financeiras.

Figura 2: Inserção dos algoritmos Logistic Regression, Tree e Random Forest no fluxo de modelagem



## Organização e Preparação da Base para os Modelos


A preparação dos dados concentrou-se, inicialmente, na definição correta da variável-alvo no widget **File**, onde a coluna **Bankrupt?** foi configurada como **target**. Essa etapa foi necessária para que os algoritmos de classificação fossem treinados sobre a variável de interesse.

Em seguida, verificou-se, com apoio dos widgets **Data Table** e **Data Info**, que a base não apresentava valores ausentes e que a maior parte dos atributos era numérica. Por essa razão, não foi necessário aplicar procedimentos de imputação de dados faltantes. Também não houve necessidade de conversão extensa de variáveis categóricas, já que o conjunto é predominantemente composto por indicadores financeiros numéricos.

A preparação adotada foi, portanto, mínima e compatível com os algoritmos escolhidos. A **Logistic Regression** recebeu os dados diretamente após a definição da target, funcionando como um modelo linear de referência. A **Tree** e o **Random Forest**, por serem métodos baseados em árvores, também foram aplicados sobre a base sem transformações adicionais relevantes, permitindo comparar os algoritmos sob condições semelhantes.

Essa escolha de preparação teve como objetivo preservar a estrutura original dos dados e avaliar, de forma mais direta, como cada algoritmo se comporta diante de uma base real, numérica e desbalanceada.

Figura 3: Organização da base de dados e definição da target para os modelos



## Condução dos Experimentos e Coleta das Métricas

Os experimentos de aprendizado foram conduzidos no widget **Test & Score** do Orange Data Mining. A base de dados foi conectada diretamente a esse widget, e os três algoritmos selecionados — **Logistic Regression**, **Tree** e **Random Forest** — foram avaliados sob o mesmo protocolo experimental.

Como estratégia de validação, utilizou-se **cross-validation** com **10 folds**, mantendo a opção **stratified** ativada. Essa configuração foi adotada para preservar, em cada partição, a proporção entre as classes da target, o que é especialmente relevante em uma base desbalanceada como a utilizada neste trabalho.


As métricas coletadas no **Widget Test & Score** foram **AUC**, **CA (Accuracy)**, **F1**, **Precision**, **Recall** e **MCC**. Inicialmente, o Orange exibia a média sobre as classes, mas, para uma análise mais aderente ao problema, os resultados foram observados especificamente para a **classe 1**, correspondente à condição de falência.

Os resultados mostraram que a **Logistic Regression** apresentou AUC de **0,576**, Accuracy de **0,964**, mas Precision, Recall e F1 iguais a **0** para a classe 1. A **Tree** apresentou AUC de **0,500**, Accuracy de **0,968** e também Precision, Recall e F1 iguais a **0** para a classe de interesse. Já o **Random Forest** obteve o melhor desempenho relativo, com AUC de **0,874**, Accuracy de **0,969**, Precision de **0,587**, Recall de **0,168**, F1 de **0,261** e MCC de **0,303**.

Além do **Widget Test & Score**, foram utilizados os widgets **Confusion Matrix**, **ROC Analysis** e **Performance Curve**. A matriz de confusão permitiu observar, no caso do **Random Forest**, a presença de **6573 verdadeiros negativos**, **26 falsos positivos**, **183 falsos negativos** e **37 verdadeiros positivos**, evidenciando que o modelo foi o único a identificar parte dos casos de falência. O **ROC Analysis** confirmou superioridade visual do Random Forest em relação aos demais modelos. Já o **Performance Curve**, configurado para **Precision-Recall** com foco na classe 1, reforçou que apenas o Random Forest apresentou comportamento minimamente útil para a classe minoritária.

Esses experimentos permitiram comparar os três algoritmos sob as mesmas condições e coletar métricas suficientes para analisar não apenas o desempenho global, mas principalmente a capacidade de detecção da classe de maior interesse no problema.

Figura 4: Avaliação dos modelos e coleta das métricas no Widget Test & Score



## Relato dos experimentos e lições aprendidas:

Os experimentos mostraram que a base utilizada apresenta forte desbalanceamento entre as classes, o que influenciou diretamente os resultados obtidos. Embora **Logistic Regression** e **Tree** tenham apresentado valores elevados de **Accuracy**, ambos falharam completamente na detecção da classe **1**, correspondente à falência, resultando em **Precision**, **Recall** e **F1** iguais a zero para essa classe. Isso evidenciou que, em problemas desbalanceados, a acurácia isoladamente pode transmitir uma impressão enganosa de bom desempenho.


O **Random Forest** apresentou o melhor resultado entre os três algoritmos testados. Foi o único modelo que conseguiu identificar parte dos casos de falência, ainda que com **Recall baixo**. A análise da matriz de confusão mostrou que o modelo acertou alguns casos positivos, mas ainda deixou escapar muitos exemplos da classe minoritária. Assim, embora superior aos demais, seu desempenho ainda esteve longe do ideal para um problema em que detectar a classe positiva é particularmente importante.

As análises com **ROC Analysis** e **Performance Curve** reforçaram esse diagnóstico. No gráfico ROC, o **Random Forest** apresentou comportamento superior aos demais modelos, coerente com o maior valor de **AUC** obtido. Já na curva **Precision-Recall**, observou-se novamente que apenas esse modelo apresentou utilidade prática para a classe de falência, enquanto os demais se mostraram ineficazes nesse aspecto.

Como principal lição aprendida, constatou-se que a escolha do melhor modelo não deve ser feita apenas com base em métricas globais. Em bases desbalanceadas, é fundamental observar métricas voltadas à classe de interesse, como **Recall**, **Precision**, **F1** e a **matriz de confusão**. Também se verificou que diferentes algoritmos respondem de maneira distinta ao mesmo conjunto de dados, sendo importante comparar abordagens lineares e baseadas em árvore para compreender melhor o problema.

De forma geral, os experimentos permitiram concluir que o Random Forest foi o modelo mais adequado entre os testados, mas também mostraram que a predição de falência, nessa base, continua sendo um desafio. O processo realizado no Orange Data Mining foi útil para estruturar a análise, comparar os algoritmos e compreender, de forma prática, os efeitos do desbalanceamento sobre a modelagem.

Figura 5: Matriz de confusão e análise do desempenho dos modelos na classe de falência



**Ferramenta de Inteligência Artificial generativa utilizada foi o Gemini AI 3 versão PRO, da Google, com a utilização de prompt para verificação de integridade do arquivo data.CSV, a saber:**

1. “(..)1. Analise o arquivo intitulado "data", em formato CSV, e verifique a integridade do arquivo.”

A IA retornou com resumo estrutural, Verificação de Integridade, Análise-Alvo e Distribuição e Observações para Modelagem no Orange e apresentou sugestões para Balanceamento, Reamostragem via Widget "Data Sampler".

O grau de contribuição é entre 0 (nenhuma) e 1 (baixa), servindo apenas de ferramenta de apoio para verificar a integridade do arquivo. Nenhuma sugestão da IA generativa foi adotada, pois não fazia sentido para o objetivo do trabalho.

**Link público compartilhável da conversa:** <https://gemini.google.com/share/2666c83c8fd3>

**Link para o arquivo do projeto do Orange e dos dados utilizados:**

**Projeto do Orange Data Mining (.ows):** anexado no arquivo CienciadedadoeIA\_fase2.zip

**Conjunto de dados utilizado (data.csv):** anexado no arquivo CienciadedadosoIA\_fase2.zip

**Fonte original do dataset:** Taiwanese Bankruptcy Prediction — UCI Machine Learning Repository, disponível em

<https://archive.ics.uci.edu/static/public/572/taiwanese+bankruptcy+prediction.zip>